LAPORAN DISKUSI DATA E-COMMERCE

Isi CSV dan persiapan dataset customer churn

Pendahuluan

Laporan ini merangkum pembahasan tentang empat CSV sumber di folder simulation dan tiga dataset pelanggan yang disiapkan untuk latihan prediksi customer churn. Ringkasan angka diperiksa dari berkas yang tersedia di workspace.

1. Berkas sumber

customers.csv - profil pelanggan

Berisi ID, negara, usia, gender, tier keanggotaan, tanggal registrasi, jumlah pesanan, total dan rata-rata belanja, hari sejak pembelian terakhir, kategori favorit, perangkat, metode pembayaran, kanal akuisisi, ulasan, retur, wishlist, newsletter, serta target churned.

orders.csv - rincian transaksi

Mencatat ID pesanan dan pelanggan, tanggal, produk/kategori, harga, kuantitas, subtotal, diskon, ongkir, pajak, total transaksi, pembayaran, perangkat, lama pengiriman, status, retur, rating, dan aktivitas sesi belanja.

monthly_revenue.csv - ringkasan bulanan

Merangkum tahun, bulan, kuartal, jumlah pesanan, pendapatan, rata-rata nilai pesanan dan diskon, tingkat retur, pelanggan unik, serta pelanggan baru.

product_summary.csv - ringkasan produk

Berisi kategori dan nama produk, jumlah pesanan, total pendapatan, harga dan rating rata-rata, tingkat retur, diskon rata-rata, serta rata-rata lama pengiriman.

Intinya: customers menjelaskan siapa pelanggan; orders mencatat transaksi; monthly_revenue merangkum penjualan per bulan; product_summary membandingkan performa produk.

2. Dataset untuk latihan churn

customer_ml_dataset.csv berisi keseluruhan data pelanggan untuk pemodelan, fitur, ID, dan target churned. Dataset ini memiliki 8.000 baris dan 23 kolom.

customer_train.csv berisi 6.400 baris (80%) untuk melatih model. customer_test.csv berisi 1.600 baris (20%) untuk mengevaluasi model pada bagian data terpisah. Nama file yang benar adalah customer_train.csv, bukan customer_traain.csv.

Fitur kategori: negara, gender, tier keanggotaan, kategori favorit, perangkat, metode pembayaran favorit, dan kanal akuisisi. Fitur numerik mencakup usia, jumlah pesanan, total belanja, rata-rata nilai pesanan, hari sejak pembelian terakhir, ulasan, skor, retur, wishlist, newsletter, serta empat fitur turunan.

Fitur turunan adalah customer_tenure_days (lama menjadi pelanggan), orders_per_year (pesanan per tahun), reviews_per_order (ulasan per pesanan), dan returns_per_order (retur per pesanan).

3. Alur persiapan data

Script simulation/data_prep.py memeriksa kolom wajib; mengubah tanggal ke format tanggal; menetapkan tanggal snapshot dari tanggal terbaru pada data; membuat empat fitur turunan; memastikan churned bertipe bilangan bulat; lalu membagi data secara stratifikasi 80:20 dengan random_state=42.

Kolom kategori tetap berupa teks di berkas hasil. Encoding kategori dilakukan di pipeline model agar transformasi dipelajari dari data train.

4. Ringkasan kualitas data

Laporan kualitas mencatat 8.000 pelanggan, 25.000 pesanan, 140 baris ringkasan produk, dan 75 baris bulanan. Churn pelanggan 8,94%; retur pesanan 8,08%; rating kosong pada 63% pesanan. Revenue pesanan Delivered sebesar USD 2.585.126,50.

monthly_revenue.csv menghitung revenue pesanan Delivered, sehingga return_rate pada ringkasan bulanan selalu nol. Untuk analisis retur, gunakan orders.csv. Jumlah revenue product_summary cocok dengan pesanan non-cancelled; revenue bulanan cocok dengan pesanan Delivered.

Catatan konteks dan penggunaan

Laporan ini membahas data e-commerce di folder simulation. Dropout/dataset.csv yang sedang terbuka di IDE adalah konteks dataset berbeda dan belum dianalisis dalam persiapan ini. Untuk mengulang proses e-commerce, jalankan python data_prep.py dari folder simulation.

Berkas keluaran: customer_ml_dataset.csv, customer_train.csv, customer_test.csv, dan data_quality_report.json.